МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №4
по курсу «Параллельная обработка данных»

Сортировка чисел на GPU. Свертка, сканирование, гистограмма.

Выполнил: К.О. Вахрамян
Группа: 8О-406Б
Преподаватели: К.Г. Крашенинников,
А.Ю. Морозов

Москва, 2022

Условие

1. Цель работы, общая постановка задачи (один абзац).
   Ознакомление с фундаментальными алгоритмами GPU: свертка (reduce), сканирование (blelloch scan) и гистограмма (histogram). Реализация одной изсортировок на CUDA.
2. Вариант на “два”. Сортировка подсчетом.
   Вариант №2, с использованием алгоритма сканирования из библиотеки Thrust.

Программное и аппаратное обеспечение

GPU:

--- General Information for device ---
Name: NVIDIA GeForce GTX 1650
Compute capability: 7.5
Clock rate: 1560000
Device copy overlap: Enabled
Kernel execution timeout : Enabled
--- Memory Information for device ---
Total global mem: 4100521984
Total constant Mem: 65536
Max mem pitch: 2147483647
Texture Alignment: 512
--- MP Information for device ---
Multiprocessor count: 16
Shared mem per mp: 49152
Registers per mp: 65536
Threads in warp: 32
Max threads per block: 1024
Max thread dimensions: (1024, 1024, 64)
Max grid dimensions: (2147483647, 65535, 65535)

CPU:

Architecture: x86_64
CPU op-mode(s): 32-bit, 64-bit
Byte Order: Little Endian
Address sizes: 39 bits physical, 48 bits virtual
CPU(s): 8
On-line CPU(s) list: 0-7
Thread(s) per core: 2
Core(s) per socket: 4
Socket(s): 1
NUMA node(s): 1
Vendor ID: GenuineIntel
CPU family: 6
Model: 158

Model name: Intel(R) Core(TM) i5-9300HF CPU @ 2.40GHz
Stepping: 13
CPU MHz: 1274.759
CPU max MHz: 2400.0000
CPU min MHz: 800.0000
BogoMIPS: 4800.00
Virtualization: VT-x
L1d cache: 128 KiB
L1i cache: 128 KiB
L2 cache: 1 MiB
L3 cache: 8 MiB

OS:
Linux Mint 20

Compiler:
nvcc

Code Editor:
VS Code

Метод решения
Сортировка подсчетом состоит из 3-х частей.

1. Гистограмма. Создается массив C, состоящий из нулей, размера N, где N — максимальный элемент. Далее производится проход по исходному массиву A и каждый C[A[i]] увеличивается на 1. Таким образом получаем частотный массив.
2. Алгоритм сканирования. В виду того, что данный алгоритм линейный, распараллеливание является нетривиальной задачей. Первый этап алгоритма — редукция. Складываем элементы, удаленные на 2^d друг от друга. В результате на n-1 позиции стоит сумма всех элементов. Второй этап — нисходящая развертка. Берутся по 2 элемента, также удаленные на 2^d друг от друга. Первый элемент суммируется со вторым и встает на его позицию, второй перемещается на позицию первого. В результате получаем массив, i-й элемент которого равен сумме предыдущих и данного.
3. Восстановление ответа. В цикле по результирующему массиву O на C[A[i]] позицию ставится A[i] элемент.

Описание программы

Гистограмма реализована при помощи атомарных операций. За счет них происходит конкурентный корректный доступ к одним и тем же участкам памяти, хотя и в угоду распараллеливания.

```
int idx = threadIdx.x + blockIdx.x * blockDim.x;
int offsetx = gridDim.x * blockDim.x;

for (int i = idx; i < size; i += offsetx)
atomicAdd(hist + data[i], 1);
```

Реализация сканирования была взята из библиотеки thrust.

```
thrust::inclusive_scan(thrust::device, hist, hist + N, hist);
```

Алгоритм работает с массивом произвольной длины.

Самостоятельно мною был реализован данный алгоритм.
Скан зависит от числа нитей в блоке и поэтому применяется над массивом определенной длины. Каждый тред обрабатывает 2 элемента.

```
__shared__ int temp[THREADS_X2];
int tID = threadIdx.x;
int ai = tID;
int bi = ai + (n >> 1);
```

Первая часть — редукция.

```
int offset = 1;
for(int d = n >> 1; d > 0; d >>= 1) {
__syncthreads();

if (tID < d) {
int aidx = offset * ((tID << 1) + 1) - 1;
int bidx = offset * ((tID << 1) + 2) - 1;
aidx += CONFLICT_FREE_OFFSET(aidx);
bidx += CONFLICT_FREE_OFFSET(bidx);

temp[bidx] += temp[aidx];
}

offset <<= 1;
}
```

макрос CONFLICT_FREE_OFFSET необходим для предотвращения конфликтов банков памяти.

Вторая часть — развертка

```
for (int d = 1; d < n; d <<= 1) {
offset >>= 1;
```

```
__syncthreads();

if (tID < d) {
int aidx = offset * ((tID << 1) + 1) - 1;
int bidx = offset * ((tID << 1) + 2) - 1;
aidx += CONFLICT_FREE_OFFSET(aidx);
bidx += CONFLICT_FREE_OFFSET(bidx);

int t = temp[aidx];
temp[aidx] = temp[bidx];
temp[bidx] += t;
}
}
```

Здесь также удалось избежать конфликтов банков памяти. Кроме того, использование битовых сдвигов вместо умножения/деления на 2 повышает производительность.

Т.к. данный алгоритм для ограниченного массива, а нам нужно обрабатывать массивы произвольной длины, используем разбиение на подмассивы.

```
__global__ void prescanArbitary(int* data, int size) {
for (int i = THREADS_X2 * blockIdx.x; i < size; i += THREADS_X2 * gridDim.x)
blockScan(data + i, THREADS_X2);
}
```

Затем в каждом подмассиве берем последний элемент и выполняем сканирование рекурсивно. Скан сумм складываем со сдвигом с исходным массивом

```
int tID = threadIdx.x;
int idx = blockIdx.x + 1;
int offsetx = gridDim.x;
for (int i = idx; i < size; i += offsetx)
atomicAdd(data + THREADS_X2 * i + tID, sums[i — 1]);
```

Результаты

	1e3	1e5	1e7
<<<1,32>>>	1.4	5.26	361.97
<<<32,32>>>	1.37	1.88	59.83
<<<1,128>>>	1.36	2.58	129.62
<<<1,1024>>>	1.36	1.86	60.87
<<<1024, 1024>>>	1.39	1.86	59.38
CPU	**94.77**	**106.05**	**1507.13**

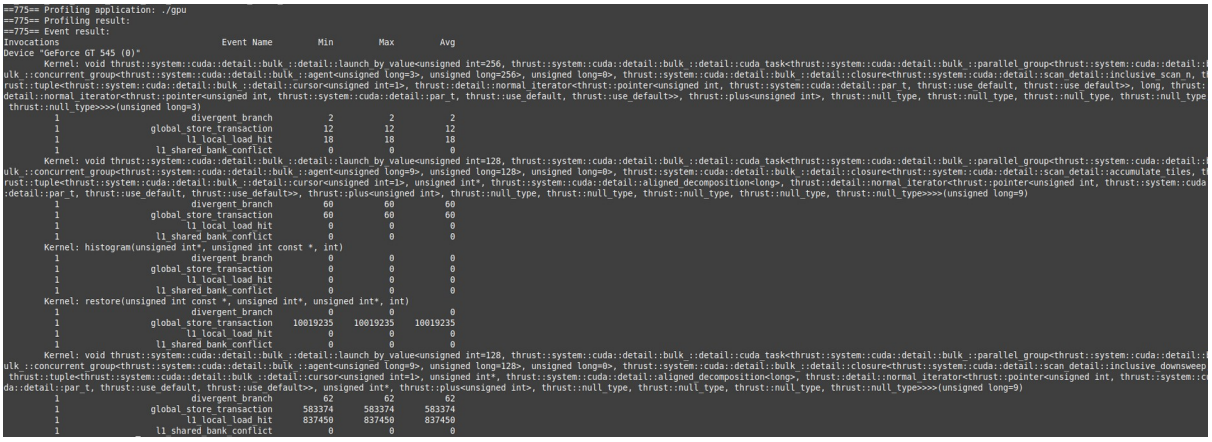

Спилинга регистров нет.

Выводы

Алгоритм сканирования может применяться с любым бинарным оператором, что делает его очень полезным. Линейные сортировки тоже используются повсеместно (там, где нужно отсортировать натуральные числа и т. д.). Что касается реализации параллельного алгоритма на CUDA, я понял идею и написал его, кроме того протестировал локально, но прохода тестов на чекере мне добиться не удалось. В связи с этим пришлось использовать библиотечную реализацию алгоритма.